

戴源君

216-269-2394 · yxd429@case.edu · 美国俄亥俄州克利夫兰

[GitHub](#) · [个人主页](#) · [技术博客](#)

教育背景

凯斯西储大学 (Case Western Reserve University)

2019年8月 — 2026年12月 (预计)

计算机科学博士候选人 · 导师: 王安教授 (NSF CAREER Award 获得者) · 美国俄亥俄州克利夫兰

研究方向: 分布式机器学习系统的可观测性、安全性与性能优化

匹兹堡大学 (University of Pittsburgh)

2014年

电气与计算机工程理学硕士 · 美国宾夕法尼亚州匹兹堡

研究方向: 计算机体系结构与微架构

东北大学

2008年

电气工程学士 · 中国辽宁省沈阳市

学术成果

- [1] *戴源君, 何某, 王安. "DYNAMIX: RL-Based Adaptive Batch Size Optimization in Distributed Machine Learning Systems." [IEEE IPDPS Workshop \(PDCO\)](#), 2026年。
- [2] *戴源君, 郭某, 王某. "PSketch: A Priority-Aware Sketch Architecture for Real-Time Flow Monitoring via eBPF." [IEEE ICNC](#), 2026年。(第一作者兼通讯作者)
- [3] *戴源君, 郭某, 王某. "eHashPipe: Lightweight Top-K and Per-PID Resource Monitoring with eBPF." [IEEE CCNC](#), 2026年。(第一作者兼通讯作者)
- [4] *戴源君, 王安, 郭某, 陈某. "Elastically Augmenting the Control-Path Throughput in SDN to Deal with Internet DDoS Attacks." [ACM Transactions on Internet Technology \(TOIT\)](#), 第23卷第1期, 2023年。
- [5] *戴源君, 郭某, 王安. "DNN Architecture Attacks via Network and Power Side Channels." [Springer SecureComm](#), 2023年。
- [6] *戴源君, 郭某, 王安. "Stealing DNN Architectures via Network and Power Side Channels." [ACM Transactions on Privacy and Security \(TOPS\)](#) — 审稿中。
- [7] 郭某, 戴源君, 王安 等. "PRISM: Priority-Based Selective Reliability for Efficient Distributed Machine Learning." 审稿中。

科研经历

研究助理

2019年8月 — 2026年12月 (预计)

凯斯西储大学 · 美国俄亥俄州克利夫兰

DYNAMIX — 基于强化学习的分布式ML自适应批量调度系统 | [论文](#) / [代码](#)

- 设计基于PPO的强化学习调度器, 通过eBPF探针实时监控CPU/内存、网络带宽、重传率等硬件信号及模型收敛速度等统计信号, 动态调整训练批量大小
- 在PyTorch DDP (Ring AllReduce) 和BytePS (参数服务器) 两种架构上验证; 在俄亥俄超算中心与Lambda Labs A100 GPU集群 (8—64个A100) 上取得**46%端到端训练加速**及约6%精度提升

PSketch / eHashPipe — 面向DML的内核级eBPF草图监控系统 | [论文\(PSketch\)](#) / [代码](#) · [论文\(eHashPipe\)](#) / [代码](#)

- **PSketch**: 设计三层内核级网络监控系统 (精确匹配哈希表 + 重流量表 (带投票机制的踢出逻辑) + 3层 Count-Min Sketch), 实现 $O(n)$ Top-K检测, 在10 Gbps上达到**96%准确率**及<1.1%吞吐量开销

- **eHashPipe**: 设计双管道eBPF可观测性框架——内存分析器 (HashPipe + ptr2size去分配追踪) + per-thread CPU追踪器 (sched_switch tracepoint), 时间分辨率比top/htop高**10—14倍**

PRISM — 面向分布式ML训练的优先级选择性可靠传输 | 预印本

- 设计介于NCCL/Gloo与UDP之间的传输层库, Hook至PyTorch DDP的AllReduce bucket-ready事件; 按梯度幅值分类为高优先级 (SACK全量重传) 与低优先级 (本地缓存补偿)
- 在32个GPU上相比TCP实现**CNN吞吐量提升8—15%, LLM提升15—21%**; 在144节点规模达到NDP延迟水平

可扩展LLM推理服务基础设施 (Kubernetes) | 代码 / 演示视频

- 独立设计并部署自托管LLM推理平台 (NGINX → FastAPI → vLLM), 通过GitOps CI/CD (ArgoCD + GitHub Actions) 管理; 支持GPU时间切片、硬件MIG分区及基于自定义指标的HPA自动扩缩容
- 构建4层GPU可观测性体系 (DCGM + Prometheus + Grafana), 覆盖GPU硬件、vLLM推理指标、FastAPI网关及K8s集群健康状态

多标签文本分类大语言模型精调 (医疗编码) | 预印本

- 基于极端不平衡医疗数据集 (MIMIC-V, 115个HCC标签) 构建多标签分类器; 采用逆频率加权损失函数和per-label阈值校准提升长尾性能
- 使用PyTorch DDP在2× RTX A6000上精调PubMedBERT; 通过NeMo + Megatron-LM + FSDP ZeRO-3 + FlashAttention精调Qwen-7B; 采用few-shot GPT-4o提示工程构建半监督标注流水线

分布式ML系统侧信道攻击分析 | 论文 / 代码

- 深入分析MXNet BSP参数服务器架构下的DML计算与通信行为; 通过push/pull原语插桩剖析各层网络流量模式
- 利用Intel RAPL (PP0+DRAM, 50μs采样) 进行ML能耗分析; 采用滑动窗口算法定位前向传播、带通滤波与K-means聚类降噪分层, 决策树分类层类型, MLP集成恢复Conv/FC维度

工作经历

软件工程师 II

2015年6月 — 2016年8月

Cisco Systems, Inc. · 美国加利福尼亚州圣何塞

- 为服务Azure、AWS、阿里云的100 Gbps核心路由器开发NPU/ASIC功能, 使用Broadcom BCM SDK; 参与数据包转发模块优化, 降低重载下的转发延迟

软件工程师实习

2014年10月 — 2015年5月

Broadcom (Emulex) · 美国加利福尼亚州圣何塞

- 将轮询式数据采集重构为DMA + 循环缓冲区架构, CPU负载降低30%; 将BladeEngine ASIC管理CLI从Linux移植至Windows Server

AI产品技术经理

2016年9月 — 2019年1月

美的集团 / 小米科技

- 美的: 主导Fun Oven II智能厨电的ML模型训练与部署 (阿里云Docker服务)、移动App及烹饪算法设计; 产品荣获**红点设计奖**, 于2018年AWE展览会发布
- 小米: 通过竞品分析与用户研究定义IoT产品需求; 评估技术可行性并提交架构方案, 对齐工程与业务团队

专业技能

编程语言 Python、C/C++

ML框架 PyTorch (DDP/FSDP)、vLLM、Megatron-LM、NCCL、BytePS、scikit-learn

并行范式 数据并行 (DDP/FSDP)、张量并行 (TP)、流水线并行 (PP)、混合并行

Agentic AI LangGraph、多智能体编排、多模型路由、提示工程

基础设施 Kubernetes、Docker、CI/CD流水线 (GitHub Actions)、ArgoCD、Slurm

可观测性 eBPF (内核追踪)、Prometheus、Grafana、DCGM Exporter、Intel RAPL

云与HPC Lambda Labs HPC、俄亥俄超算中心 (OSC)、NSF FABRIC、CloudLab

网络 SDN (软件定义网络)、P4、NPU/ASIC (Broadcom BCM SDK)

专利

一种烤箱温度控制方法、装置及计算机可读存储介质 — 授权专利 [CN 108594898 B](#) | 授权日期：2021年7月23日 | 权利人：美的集团股份有限公司 | 发明人：邵光远、戴源君 等